

Eliana Ostrovsky

Estudiante avanzada de Ingeniería en Inteligencia Artificial

Interpretabilidad de LLMs • Evaluación de Modelos • Visión por Computadora • Aprendizaje por Refuerzo

Buenos Aires, Argentina

elianaostro@gmail.com | +54 9 11 6666-2752

github.com/elianaostro | linkedin.com/in/eliana-ostro

Perfil

Estudiante avanzada de Ingeniería en Inteligencia Artificial (Top 9 % de la carrera, Universidad de San Andrés) con investigación publicada en visión por computadora y experiencia directa en interpretabilidad y evaluación del comportamiento de LLMs. Mi trabajo se ha centrado en caracterizar modos de falla de modelos de lenguaje — cámaras de eco epistémicas, impermeabilidad factual y deriva ideológica en interacción multi-agente — y en medir la degradación de sistemas de percepción bajo cambio de dominio. Me interesa contribuir a AI Safety desde las agendas de **interpretabilidad** y **evaluations**, con foco en detectar capacidades y comportamientos peligrosos antes del despliegue. Complemento la investigación con experiencia aplicada en despliegue y evaluación de LLMs open-source e infraestructura de ML.

Educación

Ingeniería en Inteligencia Artificial | Universidad de San Andrés 2023 – jul. 2027 (est.)

- Top 9 % de la carrera de Ingeniería en IA; Top 10 % de la universidad.
- Promedio: 8,72 / 10,0.

Bachiller en Ciencias Naturales (Química y Biotecnología) | ORT Argentina

- Egresada con honores.

Idiomas

Español (nativo) • Inglés (C2 — lectura fluida de literatura académica y participación en seminarios internacionales) • Hebreo (básico).

Publicaciones

Detección de Carriles mediante Destilación Teacher–Student bajo Cambio de Dominio. Aceptado en las **Jornadas Argentinas de Robótica (JAR 2026)**.

Investigación

Interpretabilidad, Evaluación de Comportamiento y Modos de Falla de LLMs en Simulación Social Multi-Agente

- Investigación en equipo sobre cómo LLMs open-source (Llama-3.3-70B, Gemma-3-27B, Qwen3-8B) razonan y se influyen mutuamente en simulaciones sociales multi-agente. Construí el enrutamiento de modelos por agente y la telemetría por llamada que hicieron posible la comparación entre arquitecturas.
- Caractericé modos de falla propios de cada arquitectura en debates abiertos — cámaras de eco epistémicas, impermeabilidad factual donde el pre-entrenamiento anula la evidencia contraria y consenso neutro evasivo —, atribuidos a la cobertura del pre-entrenamiento y al alineamiento.
- Cuantifiqué el comportamiento generativo con independencia de la precisión (Self-BLEU, distinct- n , Vendi Score, entropía) y la deriva ideológica intra-persona mediante entrevistas paramétricas en checkpoints; hallamos que las poblaciones heterogéneas colapsan en un bloqueo semántico en ausencia de información exógena.

Detección de Carriles mediante Destilación Teacher–Student bajo Cambio de Dominio

- Esquema de adaptación de dominio teacher–student con pseudo-etiquetado sobre el dataset urbano PAMPA, sin reentrenar los pesos del teacher.
- Desarrollé dos variantes de student basadas en CLERNet: una basada solo en imagen y una extensión temporal con ConvLSTM para coherencia entre cuadros.
- Caractericé el compromiso entre especialización en el dominio urbano y olvido catastrófico del dominio original.

Programa de Asistentes de Investigación — Proyecto Auto Autónomo | Universidad de San Andrés

- Primer vehículo autónomo de calle de investigación de Argentina (udes.a.edu.ar/auto-autonomo).
- Trabajo con el dataset PAMPA, el primer dataset de conducción autónoma de la región (CONICET).

Efecto Antiinflamatorio de Nanopartículas sobre el Endotelio Vascular

- Pasantía de investigación en el Laboratorio de Trombosis Experimental, Instituto de Medicina Experimental (CONICET — Academia Nacional de Medicina, Buenos Aires).
- Directoras: Dra. Nancy Charó y Dra. Mirta Schattner.

Proyectos

Plataforma de Gestión de Oposiciones de Marcas

- Plataforma web full-stack que automatiza el procesamiento semanal del boletín del INPI (Instituto Nacional de la Propiedad Industrial) y la detección de conflictos de marcas para estudios jurídicos argentinos.
- Comparé nuevas solicitudes contra las carteras de clientes combinando algoritmos complementarios: fuzzy string matching, similitud fonética, embeddings semánticos, similitud visual con CNNs y razonamiento con LLMs.
- Desarrollé la interfaz para que los abogados revisen los conflictos detectados, notifiquen a sus clientes y sigan sus respuestas a lo largo del flujo de oposición.

Navegación Autónoma (PPO)

- Modelo de Proximal Policy Optimization para agentes de conducción autónoma en un entorno de simulación Unity.

Predicción de Precios de Automóviles

- Limpieza, extracción de características y transformación de datasets automotrices en crudo; entrenamiento y ajuste fino de un modelo XGBoost con optimización sistemática de hiperparámetros.

Experiencia Profesional

AI Engineer | Bouldertech

Oct 2025 – Presente (*part-time*)

- Despliego y evalúo LLMs open-source (familia Qwen) y modelos de visión con Ollama en servidores dedicados.
- Construyo pipelines de RAG y agentes autónomos de navegación web con OpenCrawl para la extracción automatizada de datos.
- Empaquetó sistemas de IA en contenedores Docker para garantizar entornos reproducibles.

Data Analyst & AI Developer | Alephee

May 2025 – Presente (*part-time*)

- Lidero el desarrollo de herramientas internas de IA y flujos de automatización.
- Construyo agentes de orquestación basados en LLMs en n8n, integrados con Microsoft Teams, SharePoint y Azure.
- Implemento flujos que generan salidas estructuradas en JSON con capas de validación y seguridad.
- Realizo consultas sobre grandes volúmenes de datos con Microsoft SQL Server y desarrollo prototipos en AWS (Bedrock, SageMaker, S3, EC2).

Ayudante de Cátedra | Universidad de San Andrés

2024 – 2025

- Física I y Análisis Matemático III: preparé y dicté clases, corregí exámenes e informes de laboratorio.

ML Intern | DHC

2024

- Construí modelos predictivos con Machine Learning y Feature Engineering para optimizar operaciones en hospitales y centros médicos.

Habilidades Técnicas

- **Programación:** Python, SQL, C++, Java, C, JavaScript, Haskell.
- **Machine Learning:** PyTorch, Sistemas LLM, Evaluación de LLMs, RAG, Visión por Computadora, Aprendizaje por Refuerzo (PPO).
- **Infraestructura:** Docker, Git, Ollama, n8n, ROS2, Gazebo, Unity, Neo4j.
- **Cloud:** AWS (Bedrock, SageMaker, S3, EC2), Microsoft 365 (SharePoint, Teams, Azure), Google Cloud.